


自装 ubuntu20.04 如何进行本地大模型部署教程及常见问题

1.查看驱动

ctrl+alt+t 打开终端



一，查看本机 NVIDIA 显卡硬件，输入 `lspci | grep -i nvidia`，回车，

```
xiedawei@ubuntu:~$ lspci | grep -i nvidia
01:00.0 VGA compatible controller: NVIDIA Corporation Device 2d19 (rev a1)
01:00.1 Audio device: NVIDIA Corporation Device 22eb (rev a1)
```

`lspci` 是查看主板 PCI 硬件设备的命令；`grep -i nvidia` 筛选出 NVIDIA 设备。

第一行：识别到 NVIDIA 独立显卡（Device 2d19 就是 RTX5060 的硬件 ID）。

第二行：显卡自带的 HDMI 音频设备。

如果这一行没有任何输出 → 主板没有识别到 NVIDIA 显卡，大概率硬件/BIOS 问题

二 2. 查看系统提供了哪些驱动版本（看推荐版本）

输入 `ubuntu-drivers devices`，回车（因为一些问题，图暂时没有）会列出显卡型号，标着 `recommended` 的就是 Ubuntu 官方推荐稳定驱动。

记录当前已安装的驱动版本，方便升级后对比。

三，输入 `dkms status | grep nvidia` 查看驱动版本，回车（图示为 570 版本）

```
xiedawei@ubuntu:~$ dkms status | grep nvidia
nvidia, 570.211.01, 5.15.0-139-generic, x86_64: installed
nvidia, 570.211.01, 6.14.6-custom, x86_64: installed
```

自装 Ubuntu20.04 的驱动版本通常为 4xx 驱动

4xx 驱动能支持的卡（可以 CUDA 加速跑大模型/深度学习）

- GTX10 系（Pascal）
- RTX20 系（Turing）
- RTX30 系（Ampere，3060、3070、3080）

☞ 上面这些卡，4xx 驱动下：`nvidia-smi` 识别显卡 + CUDA 可用，Ollama、PyTorch 都能 GPU 跑。

但目前（就本专业学生）而言，电脑显卡通常为 RTX40 系或 RTX50 系，4xx 版本不支持，最低要求为 570 版，CUDA 算力层面（大模型、深度学习）4xx 驱动内部根本没有 Blackwell（sm_120）的 CUDA 支持

- `nvidia-smi` 也许能读出显卡名字（只是基础 PCI 识别）
- 但是 CUDA 不可用，Ollama/PyTorch 只能 CPU 跑，显卡算力完全不参与计算，导致性能及其低下

所以，我们要更新驱动，确保后续大模型跑在显卡（GPU）

上。

2. 升级驱动，这里提供两种方法

`ctrl+alt+t` 打开终端

方式 1：自动安装系统推荐驱动

输入 `sudo ubuntu-drivers autoinstall` 回车

输入后会要求输入用户密码

等待 `apt` 下载、自动安装对应驱动包

（这条命令自动选择系统推荐的稳定版本，不用手动记版本号，不容易选错）

方式 2：手动指定版本安装（例如升级到 580，适合知道目标版本的情况）

`sudo apt update`

`sudo apt install nvidia-driver-580`

`nvidia-utils-580-server` 回车

可以把 580 替换成想要的版本号（570、580 等）

安装完成必须重启电脑！`reboot`

重启后，验证驱动是否更新成功（这一步可能会出问题，可以直接跳后面）

`nvidia-smi`

看左上角 **Driver Version**，数字变成新版本号，代表升级成功。

同时看 **GPU** 信息，确认显卡识别正常。

验证 Ollama CUDA 是否正常：

```
sudo systemctl restart ollama
```

问题：

情况 1：升级后黑屏、循环登录、nvidia-smi 找不到显卡

大概率是 BIOS 开启了 Secure Boot（安全启动）

解决：重启电脑，进 BIOS，关闭 Secure Boot，再进系统。

情况 2：新驱动有问题，需要回滚旧驱动

卸载新版驱动（示例，把 580 换成你装的版本）

```
sudo apt remove --purge nvidia-driver-580
```

重装旧驱动

```
sudo apt install nvidia-driver-570 nvidia-utils-570-server
```


```
sudo reboot
```

3. 下载 ollama，拉大模型

浏览器直接下载的正确链接（复制这一条，粘贴到火狐地址栏回车）

<https://ollama.com/download/ollama-linux-amd64.tar.zst>


输入后会直接下载



Downloads（下载）文件夹

下载完成后，打开终端，复制这条解压命令执行

```
sudo tar x -C /usr -f ~/Downloads/ollama-linux-amd64.tar.zst
```



标蓝部分看自己文件名叫啥，记得改

输入你的电脑密码（输密码屏幕不会显示小黑点，正常，敲完回车）（有的可能没有）

解压完，验证是否装好

ollama -v

能出版版本号，说明 ollama 成功安装。


启动 ollama 服务

ollama serve


这个终端窗口保持打开，再新建另外一个终端窗口，拉模型：

（这里以 deepseek 为按例）

ollama run deepseek-r1:7b



这样就完成了

A terminal window titled 'xiedawei@ubuntu: ~' with standard window controls. The terminal output shows the command 'ollama run deepseek-r1:7b' being executed. The progress is as follows: 'pulling manifest' is complete; 'pulling 96c415656d37: 100%' is complete with a progress bar; 'pulling f4d24e9138dd: 100%' is complete with a progress bar; 'verifying sha256 digest' is complete; 'writing manifest' is complete; and 'success' is displayed. On the right side of the terminal, a status bar shows '4.7 GB/4.7 GB', '18 MB/s', and '0s'. Below the output, a prompt 'I' is visible, and at the bottom, it says '>>> Send a message (/? for help)'. The terminal background is dark purple with light green text.

```
xiedawei@ubuntu:~$ ollama run deepseek-r1:7b
pulling manifest
pulling 96c415656d37: 100% [progress bar] 4.7 GB/4.7 GB 18 MB/s 0s
pulling f4d24e9138dd: 100% [progress bar] 148 B
verifying sha256 digest
writing manifest
success
>>> Send a message (/? for help)
I
```

4. 后续启动，以 deepseek 为例

方式一：手动启动（现在这种方式，最简单，推荐调试 ROS+AI 时用）

1. 打开终端 A，启动服务

```
ollama serve
```

保持这个窗口一直开着，最小化可以，千万别关闭。启动成功后会打印 GPU 信息。

2. 打开终端 B，运行模型对话

```
ollama run deepseek-r1:7b
```

输入文字直接聊天；输入 `/exit` 退出对话，但是终端 A 的 `serve` 依旧保持运行。

如果想换别的模型： `ollama run 模型名`

方式二：设置开机后台自启（不用每次手动敲 `ollama serve`，适合长期开发）

如果你不想每次开机开两个终端，可以设置 `systemd` 服务，后台常驻。

创建服务文件

```
sudo nano /etc/systemd/system/ollama.service
```

粘贴下面内容：

```
[Unit]
```

```
Description=Ollama Service
```

```
After=network-online.target
```

```
[Service]
```

```
ExecStart=/usr/bin/ollama serve
```

```
User=root
```

```
Restart=always
```

```
RestartSec=3
```

```
[Install]
```

```
WantedBy=default.target
```

按 `Ctrl+O` 保存，回车； `Ctrl+X` 退出 nano 编辑器。

然后执行： `sudo systemctl daemon-reload`

```
sudo systemctl enable ollama
```

```
sudo systemctl start ollama
```


设置完成：以后开机自动后台跑 `ollama serve`。

之后只需要新开任意终端直接运行：

```
ollama run deepseek-r1:7b
```

不再需要手动敲 `ollama serve`。

查看服务状态：

```
systemctl status ollama
```

关闭自启：`sudo systemctl disable ollama`

🔑 常用命令备忘

- 查看本地已经下载好的模型：`ollama list`
- 删除模型：`ollama rm deepseek-r1:7b`
- 停止后台 `ollama` 服务：`sudo systemctl stop ollama`

重点提醒

1. 手动模式：`ollama serve` 窗口关闭=服务停止
2. 自启模式：系统后台运行，关掉所有终端也能调用，ROS 程序可以直接访问接口

注：因为部分原因，本人在摸索时没有拍照，所以很多步骤没有参考图片，希望各位能够补充